전사 업무 지원 Multi-Domain RAG 챗봇 서비스

---

1. 프로젝트 개요

a. 프로젝트 이름

전사 업무 지원 Multi-Domain RAG 챗봇 서비스

b. 프로젝트 유형

개인 프로젝트

c. 담당 역할

- 전체 시스템 설계 및 아키텍처 구성
- 멀티 도메인 Chroma 벡터 DB 구성 및 RAG 파이프라인 구축
- Streamlit 프론트엔드 UI 개발
- Docker 기반 컨테이너 환경 구성

d. 사용 기술 스택 (Tech Stack)

구분	기술
언어	Python 3.11
AI 오케스트레이션	LangGraph
RAG 프레임워크	LangChain
LLM	OpenAI gpt-4o-mini
임베딩	OpenAI text-embedding-3-small
벡터 DB	Chroma
백엔드	FastAPI
프론트엔드	Streamlit
인프라	Docker

e. 한 줄 설명

사용자 질문을 자동으로 5개 업무 도메인 중 한 개로 분류하고 도메인별 사내 지식 문서를 RAG로 검색해 즉각 답변하는 전사 AI 챗봇 서비스

---

2. 문제 정의 및 접근 방식

a. 해결하려는 문제

현장 작업자, 일반 직원, 영업 담당자, 신입 사원 등 다양한 직군이 업무 중 발생하는 질문을 담당 부서나 담당자에게 매번 문의해야 하는 비효율이 존재했다. 특히 아래 상황이 반복적으로 발생했다.

- 현장 작업자: 설비 이상 및 에러 코드 발생 시 매뉴얼을 직접 뒤져야 함
- 일반 직원: 연차, 출장비, 재택근무 등의 인사 규정을 몰라 HR 부서에 반복 문의
- IT 장애: VPN, SAP, 메일 오류 발생 시 헬프데스크 대기 시간 발생
- 영업 담당자: 제품 스펙, 경쟁사 비교 자료를 실시간으로 참고하기 어려움
- 신입 직원: 공정 흐름, 품질 기준 등 온보딩 사항 접근 경로 불명확

b. 기존 방식의 한계

기존 문제	한계
담당 부서 직접 문의	응답 지연, 반복 업무 발생
방대한 사내 문서 직접 검색	원하는 정보를 찾기 어렵고 시간 소요
도메인별 담당자가 달라 어디에 물어볼지 모름	잘못된 부서로 문의 후 재문의 발생
현장 작업자가 설비 사진으로 상황 설명 불가	원격 지원 한계
지식 문서 업데이트 시 전파 지연	최신 정보 반영 어려움

c. 솔루션 및 핵심 아이디어

- **LLM 기반 자동 도메인 라우팅**: 사용자가 도메인을 직접 선택하지 않아도 질문 의도를 LLM이 파악하여 5개 도메인 중 적합한 RAG 파이프라인으로 자동 연결
- **도메인별 독립 RAG 파이프라인**: 각 업무 도메인의 지식 문서를 Chroma 컬렉션으로 독립 관리, 도메인 간 간섭 없이 정확한 문서 검색
- **LangGraph 상태 그래프**: router → retriever → generator 3단계 노드 파이프라인으로 대화 상태(domain, context, sources)를 명시적으로 관리
- **멀티모달 지원**: 현장 사진을 Base64로 인코딩하여 LLM이 텍스트와 이미지를 함께 분석

---

3. 구현

a. 시스템 아키텍처

```
사용자 질문 (텍스트 + 선택적 이미지)
        │
        ▼
  [Streamlit 프론트엔드]
  - 도메인 배지 표시
  - 참고 문서 출처 표시
  - 이미지 업로드 (Base64 인코딩)
        │ POST /chat
        ▼
  [FastAPI 백엔드]
        │
        ▼
  [LangGraph 파이프라인]
```

```
    ┌──────────────────────────────┐
    │ router_node                  │
    │  LLM 기반 도메인 분류        │
    │  + 키워드 폴백 분류          │
    └──────────────────────────────┘
                  │ domain 결정
                  ▼
    ┌──────────────────────────────┐
    │ retriever_node               │
    │  Chroma 벡터 DB 검색         │
    │  도메인별 컬렉션에서 Top-K 문서│
    └──────────────────────────────┘
                  │ context + sources
                  ▼
    ┌──────────────────────────────┐
    │ generator_node               │
    │  도메인 전용 System Prompt   │
    │  LLM 답변 생성               │
    └──────────────────────────────┘
                  │
                  ▼
  {reply, domain, sources} → 프론트엔드 응답
```

b. 데이터 파이프라인

```
지식 문서(.txt)
    │
    ▼
TextLoader (LangChain)
    │
    ▼
RecursiveCharacterTextSplitter
(chunk_size=500, overlap=80)
    │
    ▼
OpenAI Embedding
(text-embedding-3-small)
    │
    ▼
Chroma 벡터 DB
(도메인별 독립 컬렉션)
    │
    ▼
유사도 검색 → Top-K 문서 반환
```

도메인별 지식 문서 구성 (총 10개)

도메인	파일	내용
manual	equipment_manual.txt	PA-100 장비 사양, 알람 코드, 필터 교체 주기

도메인	파일	내용
manual	safety_manual.txt	LOTO 절차, 안전 수칙, PPE 기준
manual	troubleshooting.txt	에러 코드(E-201~E-205) 조치 절차
hr	hr_policy.txt	근무 시간, 복지, 인사 규정
hr	expense_policy.txt	국내/해외 출장비 기준, 경비 처리 절차
hr	vacation_policy.txt	연차 발생/이월/수당, 재택근무 규정
it	vpn_troubleshooting.txt	VPN 오류 유형별 해결 방법
it	email_issue.txt	메일 용량 관리, SAP 로그인 문제
sales	product_info.txt	A/B 제품 스펙, 가격, 특징
sales	competitor_analysis.txt	경쟁사 대비 강약점, 대응 전략
education	training_manual.txt	신입 온보딩 절차, 사내 시스템 사용법
education	process_guide.txt	생산 공정 흐름, 품질 검사 기준

c. 주요 기능 설명

1. **자동 도메인 라우팅**: 사용자 질문을 LLM이 5개 도메인(현장 매뉴얼 / HR / IT / 영업 / 교육) 중 하나로 자동 분류
2. **도메인별 RAG 답변**: 해당 도메인의 지식 문서에서 관련 청크를 검색하여 정확한 답변 생성
3. **참고 문서 출처 표시**: 모든 응답에 답변 근거가 된 지식 문서 파일명 제공
4. **멀티모달 지원**: 현장 사진 업로드 → LLM이 텍스트와 이미지를 함께 분석하여 답변
5. **대화 컨텍스트 유지**: Thread ID 기반 세션 관리로 멀티턴 대화 지원
6. **Docker 기반 배포**: 단일 명령으로 백엔드·프론트엔드·벡터 DB 전체 실행

d. 핵심 알고리즘 / 로직

LLM 기반 도메인 라우터 (이중 안전장치)

```
def classify_domain(query: str) -> str:
    # 1차: LLM이 도메인 키 하나만 출력하도록 강제하는 System Prompt
    response = _router_llm.invoke([("system", _ROUTER_SYSTEM), ("human",
query)])
    domain = response.content.strip().lower()

    # 2차: LLM 응답이 유효하지 않으면 키워드 매칭으로 폴백
    if domain not in valid_domains:
        domain = _keyword_fallback(query)
    return domain
```

LangGraph 상태 그래프 (ChatState)

```
class ChatState(TypedDict):
    messages: Annotated[List[BaseMessage], add_messages]  # 대화 이력
```

```
    domain: str         # 분류된 도메인 키
    context: str        # 검색된 문서 텍스트
    sources: List[str] # 참고 문서 파일명 목록
```

e. 데이터 처리 방식

- **청킹**: RecursiveCharacterTextSplitter (chunk_size=500, overlap=80)로 문서를 의미 단위로 분할
- **임베딩**: OpenAI text-embedding-3-small로 청크를 벡터화
- **저장**: Chroma 도메인별 독립 컬렉션 (`rag_manual`, `rag_hr`, `rag_it`, `rag_sales`, `rag_education`)
- **캐싱**: `_retrievers` 딕셔너리로 메모리 캐시 구성 → 중복 벡터 DB 로드 방지
- **검색**: 유사도 기반 Top-K 문서 검색

f. 주요 코드 구조

```
langgraph-rag-service/
├── backend/
│   ├── app/
│   │   ├── graph.py      # LangGraph 3-노드 파이프라인
│   │   ├── router.py     # LLM 도메인 분류 + 키워드 폴백
│   │   ├── rag.py        # 멀티 도메인 Chroma 벡터 스토어
│   │   ├── tools.py      # 도메인별 RAG 도구 (에이전트 확장용)
│   │   └── config.py     # 환경 변수 설정
│   ├── knowledge/        # 도메인별 지식 문서
│   │   ├── manual/
│   │   ├── hr/
│   │   ├── it/
│   │   ├── sales/
│   │   └── education/
│   └── main.py           # FastAPI 앱 진입점
├── frontend/
│   └── streamlit_app.py  # 챗봇 UI
├── tests/
│   └── test_scenarios.md # 테스트 시나리오 문서
└── docker-compose.yml
```

g. 성능 최적화 방법

- **검색기 메모리 캐싱**: 벡터 DB를 최초 1회만 로드하고 `_retrievers` 딕셔너리에 캐싱하여 이후 요청에서 재사용
- **도메인별 컬렉션 분리**: 단일 컬렉션 전체 검색 대신 도메인별 독립 컬렉션으로 검색 범위 최소화 → 검색 속도 및 정확도 향상
- **청크 크기 최적화**: chunk_size=500, overlap=80으로 설정해 문맥 손실 없이 검색 정밀도 확보
- **Docker 헬스 체크**: 백엔드 준비 완료 후 프론트엔드가 시작되는 `depends_on` + `service_healthy` 설정으로 안정적인 서비스 기동

h. 문제 해결 과정

문제 1: LLM 라우터가 예상치 못한 텍스트를 반환하는 경우

- 원인: LLM이 도메인 키 외에 부연 설명을 추가하거나 존재하지 않는 도메인명을 출력

- 해결: LLM 응답 유효성 검사 후 유효하지 않으면 한국어 키워드 매칭(`_keyword_fallback`)으로 폴백하는 이중 안전장치 구현

문제 2: 멀티모달 메시지 파싱 오류

- 원인: 이미지가 첨부된 HumanMessage의 content가 리스트 형태로 전달되어 텍스트 추출 실패
- 해결: `_get_last_human_text()` 함수에서 content 타입을 확인 후 리스트이면 `type: "text"` 파트만 추출하는 로직 추가

문제 3: 벡터 DB 중복 로드 문제

- 원인: 요청마다 Chroma 컬렉션을 새로 로드하면서 메모리 및 시간 낭비 발생
- 해결: `_retrievers` 딕셔너리 캐시를 통해 최초 1회 로드 후 재사용

---

4. 결과

a. 주요 결과 (지표, 성능)

지표	결과
도메인 라우팅 정확도	**13/13 (100%)** — 목표치 90% 초과 달성
구현 요구사항 달성률	**14/14 (100%)**
지원 도메인 수	5개 (현장 매뉴얼 / HR / IT / 영업 / 교육)
지식 문서 수	10개
테스트 케이스 수	13개 (전 케이스 통과)

b. 이전 대비 개선 사항

항목	이전 (단일 LLM 호출)	이후 (LangGraph RAG)
답변 근거	모델 학습 데이터 기반 (hallucination 위험)	실제 사내 지식 문서 기반
도메인 처리	단일 응답	5개 도메인 자동 라우팅
출처 투명성	없음	참고 문서 파일명 제공
이미지 분석	불가	현장 사진 업로드 및 멀티모달 분석
지식 업데이트	모델 재훈련 필요	지식 문서 교체만으로 즉시 반영

d. 스크린샷

테스트 결과 화면 설명

초기 화면 (`첫인사.png`)

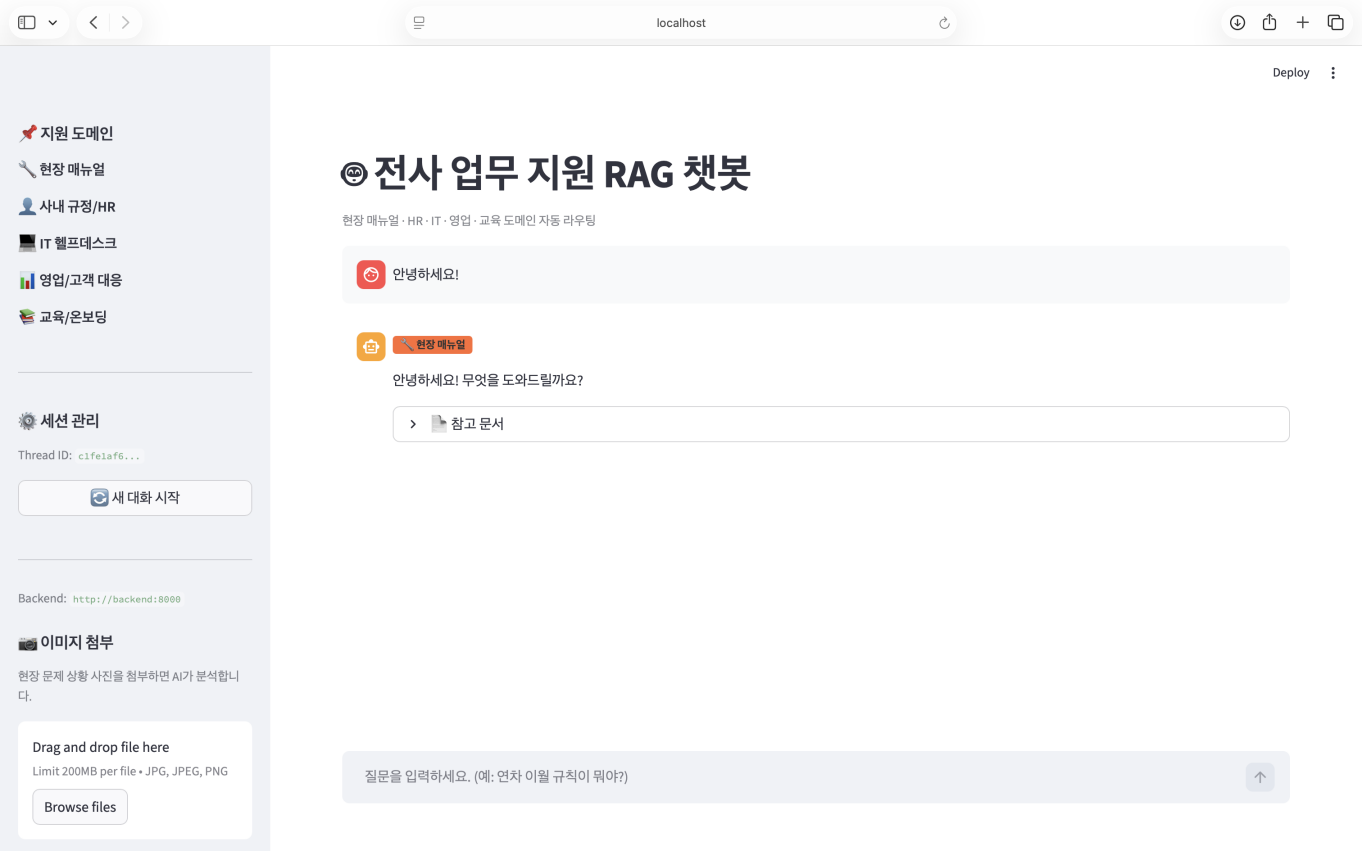

서비스 최초 접속 시의 화면이다.

- **좌측 사이드바**: 지원 도메인 목록(현장 매뉴얼, 사내 규정/HR, IT 헬프데스크, 영업/고객 대응, 교육/온보딩), 세션 Thread ID, 새 대화 시작 버튼, 이미지 첨부 영역이 표시된다.
- **중앙 채팅 영역**: "전사 업무 지원 RAG 챗봇" 타이틀과 함께 도메인 자동 라우팅 안내 캡션이 표시된다. 사용자가 "안녕하세요!"로 인사하자 챗봇이 🔧 현장 매뉴얼 도메인 배지와 함께 응답한 모습이다.
- **하단**: 질문 입력창이 위치하며 예시 질문이 placeholder로 안내된다.

사내 규정/HR 도메인 테스트

출장비 규정 (`HR_1.png`)

출장비 규정 뭐야?

사내 규정/HR

출장비 규정은 국내 및 해외 출장 시 발생하는 비용에 대한 규정을 정리한 것입니다. 아래에 각 항목별로 설명드리겠습니다.

1. 국내 출장

- **일비**: 일 30,000원 (당일 출장 시 20,000원)
- **숙박비**: 실비 정산, 1박 최대 100,000원 (서울/수도권), 80,000원 (기타 지역)
- **교통비**: 실비 정산 (영수증 첨부 필수)
  - KTX/항공: 이코노미 기준 실비
  - 자가용 이용: km당 200원
- **식비**: 조식 8,000원, 중식 10,000원, 석식 12,000원 (영수증 불필요)

2. 해외 출장

- **일비**: 국가별 상이 (인사부 출장 규정 참조)
  - 미주/유럽: USD 60 상당
  - 동남아시아: USD 40 상당
  - 일본/중국: USD 50 상당
- **숙박**: 실비 (비즈니스급 기준)
- **항공**: 이코노미 (10시간 이상 비즈니스 가능, 팀장 이상 사전 승인 필요)
- **여행자 보험**: 회사 단체 보험 자동 적용

질문을 입력하세요. (예: 연차 이월 규칙이 뭐야?)

입력: "출장비 규정 뭐야?"

- **라우팅 결과**: 사내 규정/HR 도메인으로 정확히 분류
- **답변 내용**: 국내/해외 출장비 규정을 구조화된 형식으로 상세 안내
  - 국내: 일비 30,000원, 숙박비 실비(서울 최대 100,000원), 교통비 실비, 식비 항목별 기준
  - 해외: 지역별 일비(미주/유럽 USD 60, 동남아 USD 40, 일본/중국 USD 50), 항공/보험 규정
- **검증**: `expense_policy.txt` 지식 문서 기반으로 정확한 수치 데이터 포함

연차 이월 규칙 (`HR_2.png`)

입력: "연차 이월 규칙이 어떻게 돼?"

- **라우팅 결과**: 사내 규정/HR 도메인으로 정확히 분류
- **답변 내용**:
  1. 당해 연도 미사용 연차는 원칙적으로 이월 불가
  2. 예외 조건(업무상 불가피한 사유, 팀장 확인서, 인사팀 승인, 12월 15일까지 신청) 안내
  3. 최대 5일 이월 가능, 미사용 연차는 연차 수당으로 지급(통상임금 기준)
- **하단 참고 문서 접기/펼치기 UI**: 답변 근거 문서를 확인할 수 있는 expander 컴포넌트 구현

재택근무 신청 절차 (`HR_3.png`)

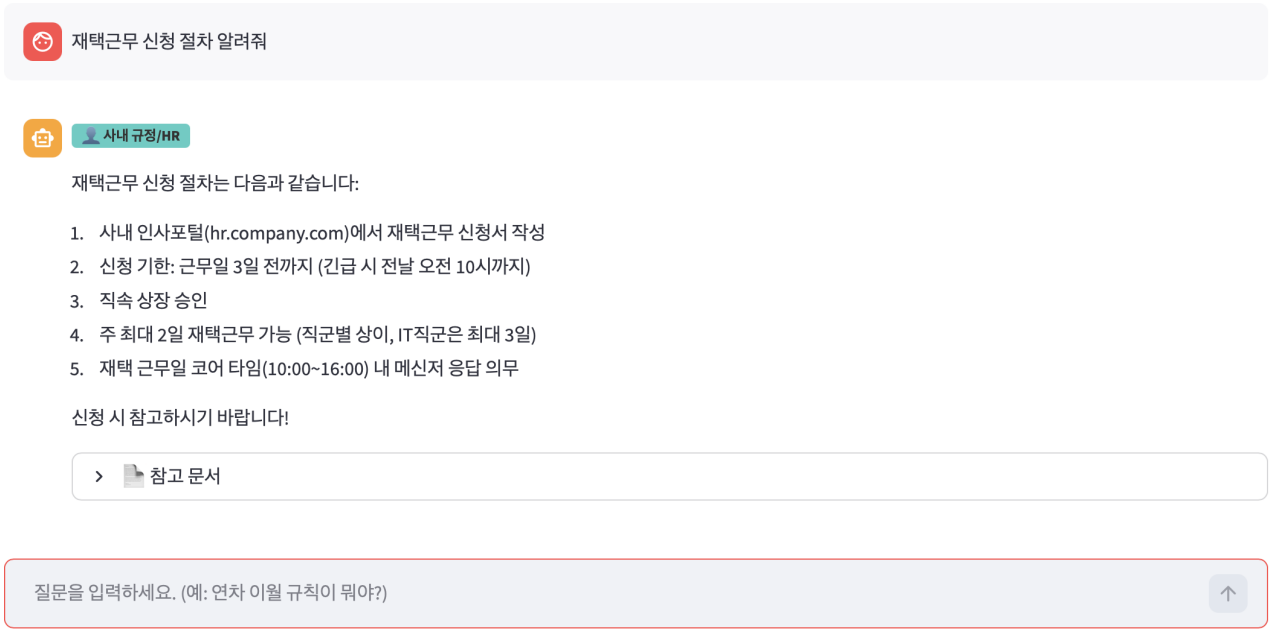

입력: "재택근무 신청 절차 알려줘"

- **라우팅 결과**: 사내 규정/HR 도메인으로 정확히 분류

- **답변 내용**: 5단계 절차를 번호 목록으로 안내
    1. 사내 인사포털(hr.company.com)에서 재택근무 신청서 작성
    2. 신청 기한: 근무일 3일 전(긴급 시 전날 오전 10시)
    3. 직속 상장 승인
    4. 주 최대 2일(IT직군 최대 3일)
    5. 코어 타임(10:00~16:00) 내 메신저 응답 의무

IT 헬프데스크 도메인 테스트

VPN 접속 문제 (`IT_1.png`)

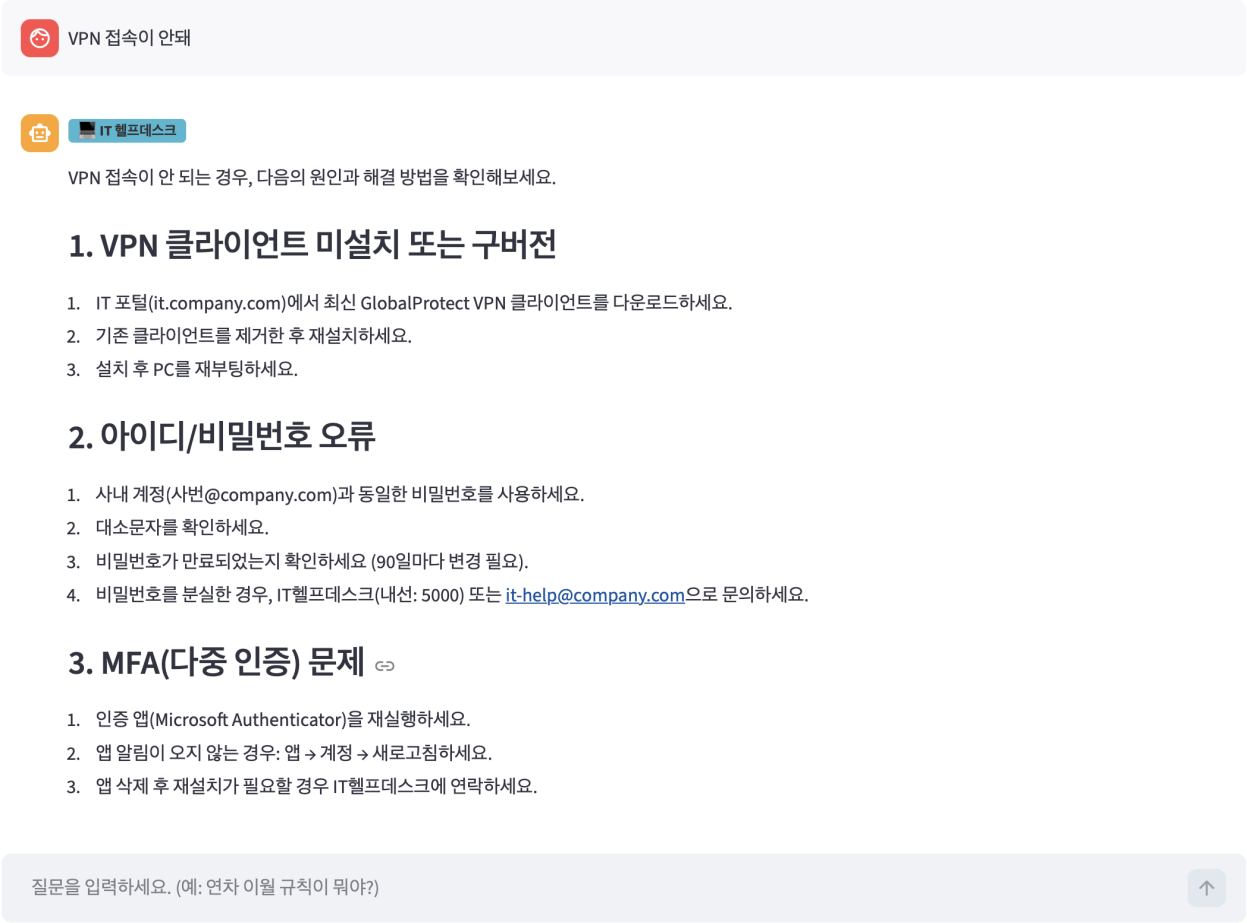

입력: "VPN 접속이 안돼"

- **라우팅 결과**: `IT 헬프데스크` 도메인으로 정확히 분류
- **답변 내용**: 원인별 해결 방법을 헤더로 구분하여 안내
    - VPN 클라이언트 미설치/구버전: GlobalProtect 재설치 절차
    - 아이디/비밀번호 오류: 사내 계정 동일 비밀번호, 90일 변경 주기, IT헬프데스크(내선 5000) 안내
    - MFA(다중 인증) 문제: Microsoft Authenticator 재실행 및 재설치 방법

SAP 로그인 잠금 (`IT_2.png`)

SAP 로그인이 안 돼. 계정이 잠겼다고 나와

IT 헬프데스크

계정이 잠겼다는 오류는 비밀번호를 5회 잘못 입력했을 때 발생합니다. 계정을 잠금 해제하려면 다음 단계를 따라주세요:

1. IT 헬프데스크에 연락하여 잠금 해제를 요청하세요. 내선 번호는 5000입니다.
2. 또는 SAP 담당자에게 연락하여(내선: 5100) 잠금 해제를 요청할 수 있습니다.

빠른 해결을 위해 해당 내선으로 연락해 주시기 바랍니다. 추가 도움이 필요하시면 말씀해 주세요!

참고 문서

질문을 입력하세요. (예: 연차 이월 규칙이 뭐야?)

입력: "SAP 로그인이 안 돼. 계정이 잠겼다고 나와"

- **라우팅 결과**: `IT 헬프데스크` 도메인으로 정확히 분류
- **답변 내용**: 비밀번호 5회 오류로 계정 잠금 발생 원인 설명 및 해제 방법(IT헬프데스크 내선 5000, SAP 담당자 내선 5100)을 간결하게 안내
- **특징**: 해결 불가 시 담당자 연락 정보를 구체적인 내선 번호와 함께 제공하는 설계가 반영됨

메일 용량 초과 (`IT_3.png`)

메일 용량 초과 해결 방법이 뭐야?

IT 헬프데스크

메일 용량 초과 문제를 해결하는 방법은 다음과 같습니다:

1. **받은 편지함 정리**: 대용량 첨부 파일이 포함된 메일을 삭제합니다.
   - Outlook에서 정렬 기준을 "크기 순"으로 설정하여 불필요한 메일을 삭제하세요.
2. **삭제된 항목 폴더 비우기**:
   - Outlook에서 "삭제된 항목" 폴더를 우클릭하고 "삭제된 항목 폴더 비우기"를 선택합니다.
3. **보낸 편지함 정리**: 대용량 첨부 파일이 포함된 보낸 메일을 삭제합니다.
4. **정크 메일 폴더 비우기**: 정크 메일 폴더의 내용을 비워주세요.

추가 조치:

- 대용량 파일(10MB 이상)을 공유할 때는 이메일 첨부 대신 사내 파일 서버 링크를 사용하세요.
- 메일함 용량 증설이 필요하면 IT 헬프데스크(내선: 5000)로 요청하세요.
- 현재 메일함 크기를 확인하려면 Outlook에서 "파일" → "계정 설정" → "데이터 파일"로 이동하세요.

이 방법들을 통해 메일 용량 초과 문제를 해결할 수 있습니다. 도움이 필요하시면 언제든지 말씀해 주세요!

참고 문서

질문을 입력하세요. (예: 연차 이월 규칙이 뭐야?)

입력: "메일 용량 초과 해결 방법이 뭐야?"

- **라우팅 결과**: `IT 헬프데스크` 도메인으로 정확히 분류
- **답변 내용**: 4단계 정리 방법(받은 편지함·삭제된 항목·보낸 편지함·정크 메일 정리) + 추가 조치(10MB 이상 파일은 사내 파일 서버 링크 활용, 용량 증설 신청 방법, 현재 용량 확인 경로) 상세 안내

영업/고객 대응 도메인 테스트

A제품 vs B제품 비교 (`고객대응_1.png`)

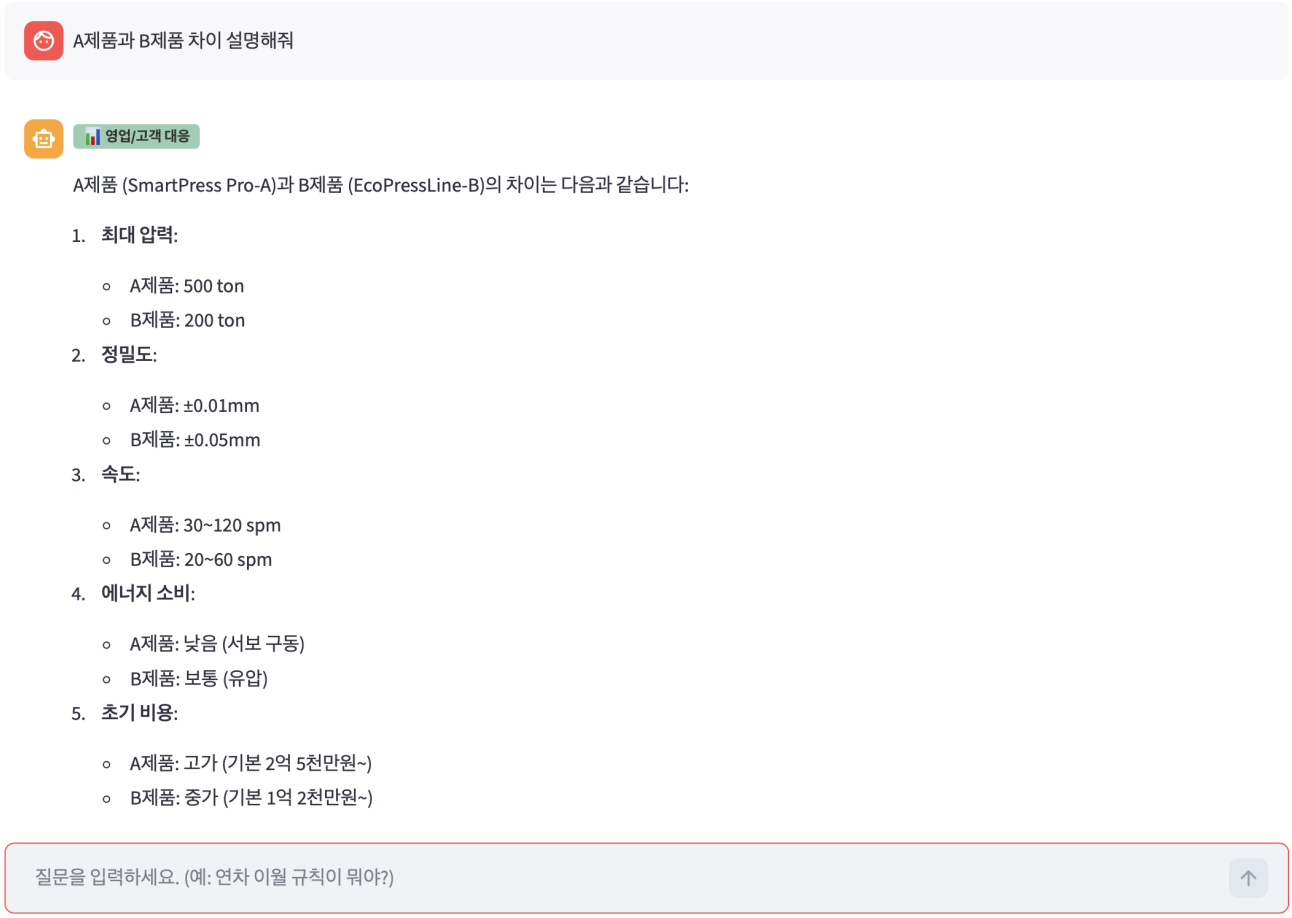

입력: "A제품과 B제품 차이 설명해줘"

- **라우팅 결과**: `영업/고객 대응` 도메인으로 정확히 분류
- **답변 내용**: SmartPress Pro-A와 EcoPressLine-B의 5개 항목 비교
  - 최대 압력: 500 ton vs 200 ton
  - 정밀도: ±0.01mm vs ±0.05mm
  - 속도: 30~120 spm vs 20~60 spm
  - 에너지 소비: 낮음(서보 구동) vs 보통(유압)
  - 초기 비용: 2억 5천만 원~ vs 1억 2천만 원~

고객 경쟁사 비교 요청 대응 (`고객대응_2.png`)

고객이 경쟁사 제품이랑 비교해달라고 하면 어떻게 답해?

📊 영업/고객 대응

고객이 경쟁사 제품과 비교해달라고 요청하신 경우, 다음과 같은 단계로 답변할 수 있습니다:

1. **경쟁사 제품 소개**: 고객이 비교하고자 하는 경쟁사 제품의 이름과 특징을 간단히 소개합니다.
   - 예: "경쟁사 A사의 UltraPress-500은 국내 최대 점유율을 보유하고 있으며, 저렴한 소모품 가격이 강점입니다."
2. **자사 제품과의 비교**: 자사 제품(A제품)과 경쟁사 제품(B제품)의 주요 차이점을 비교합니다.
   - 예: "A제품(SmartPress Pro-A)은 최대 압력이 500 ton으로, 정밀도가 ±0.01mm이며, 에너지 소비가 낮습니다. 반면, B제품(EcoPressLine-B)은 최대 압력이 200 ton이고, 정밀도가 ±0.05mm입니다."
3. **강점 및 약점 강조**: 자사 제품의 강점을 부각시키고, 경쟁사 제품의 약점을 언급합니다.
   - 예: "A제품은 IoT 및 자동화 기능이 탑재되어 있어 스마트 팩토리와의 연동이 용이합니다. 반면, 경쟁사 A사는 스마트 기능이 부족하고 에너지 소비량이 높습니다."
4. **고객의 요구에 맞춘 추천**: 고객의 요구 사항에 따라 어떤 제품이 더 적합한지 추천합니다.
   - 예: "대량 생산과 고정밀 부품을 원하신다면 A제품을 추천드리며, 비용 효율을 중시하신다면 B제품이 적합할 수 있습니다."
5. **추가 질문 유도**: 고객이 더 궁금한 점이 있으면 질문하도록 유도합니다.
   - 예: "더 궁금하신 점이나 구체적인 요구 사항이 있으시면 말씀해 주세요."

이런 방식으로 고객에게 친절하고 상세하게 답변할 수 있습니다.

> 참고 문서

질문을 입력하세요. (예: 연차 이월 규칙이 뭐야?)

입력: "고객이 경쟁사 제품이랑 비교해달라고 하면 어떻게 답해?"

- **라우팅 결과**: 영업/고객 대응 도메인으로 정확히 분류
- **답변 내용**: 고객 응대 5단계 전략 제시
  1. 경쟁사 제품 소개(객관적 특징 언급)
  2. 자사 제품과의 비교(스펙 기반)
  3. 강점 부각 + 경쟁사 약점 언급
  4. 고객 요구에 맞춘 추천
  5. 추가 질문 유도
- **특징**: 단순 정보 검색을 넘어 영업 담당자가 실제로 활용할 수 있는 대응 전략을 제시함

교육/온보딩 도메인 테스트

품질 검사 기준 (`교육_1.png`)

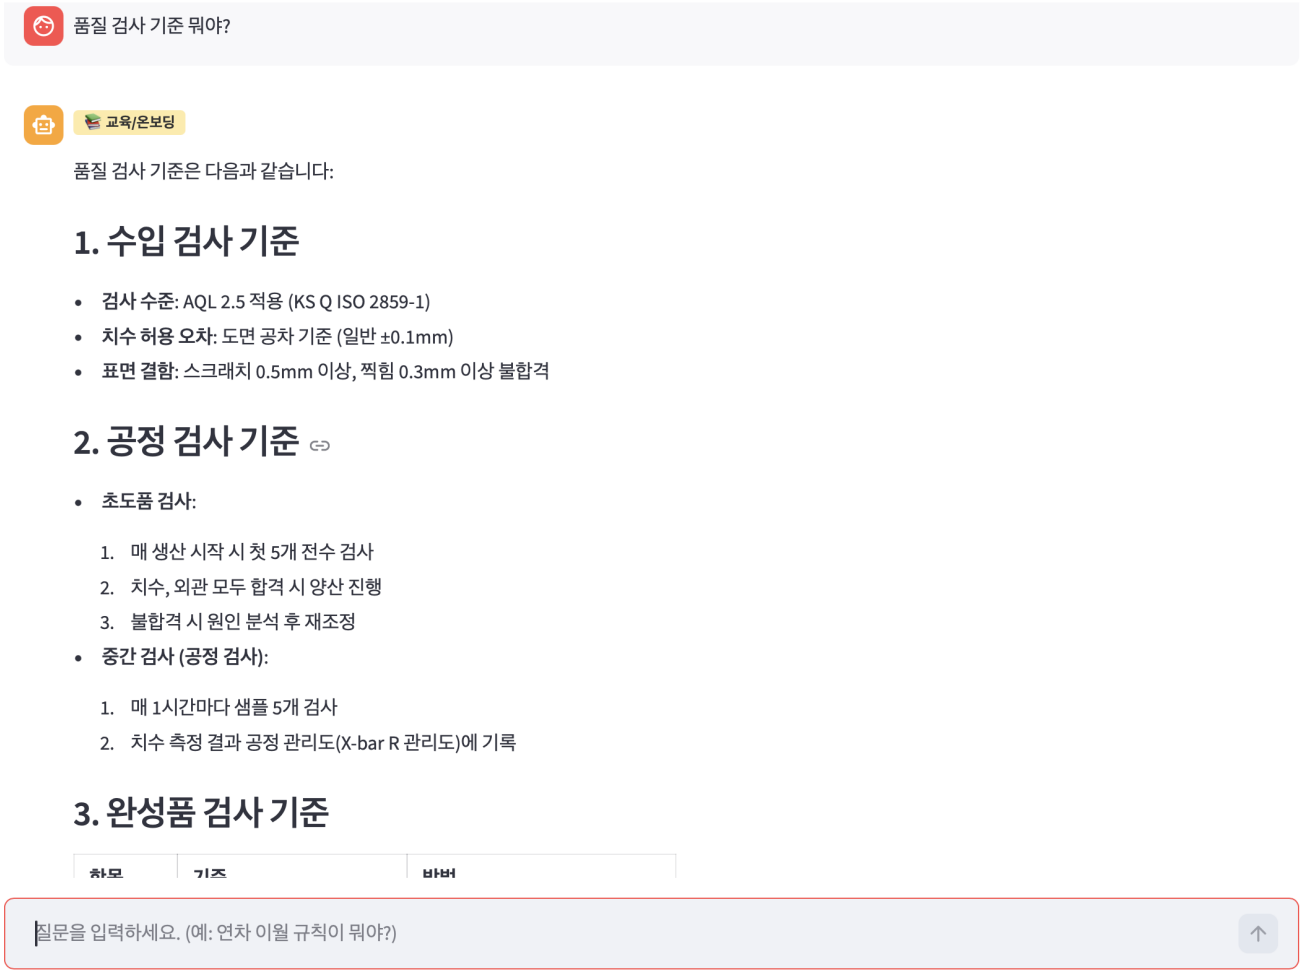

입력: "품질 검사 기준 뭐야?"

- **라우팅 결과**: 교육/온보딩 도메인으로 정확히 분류
- **답변 내용**: 3단계 검사 기준을 구조화하여 안내
  - 수입 검사: AQL 2.5 적용(KS Q ISO 2859-1), 치수 허용 오차 ±0.1mm, 표면 결함 기준
  - 공정 검사: 초도품 5개 전수 검사, 매 1시간마다 샘플 5개 측정
  - 완성품 검사: 항목별 기준/방법 표 형식으로 제공

공정 전체 흐름 (교육_2.png)

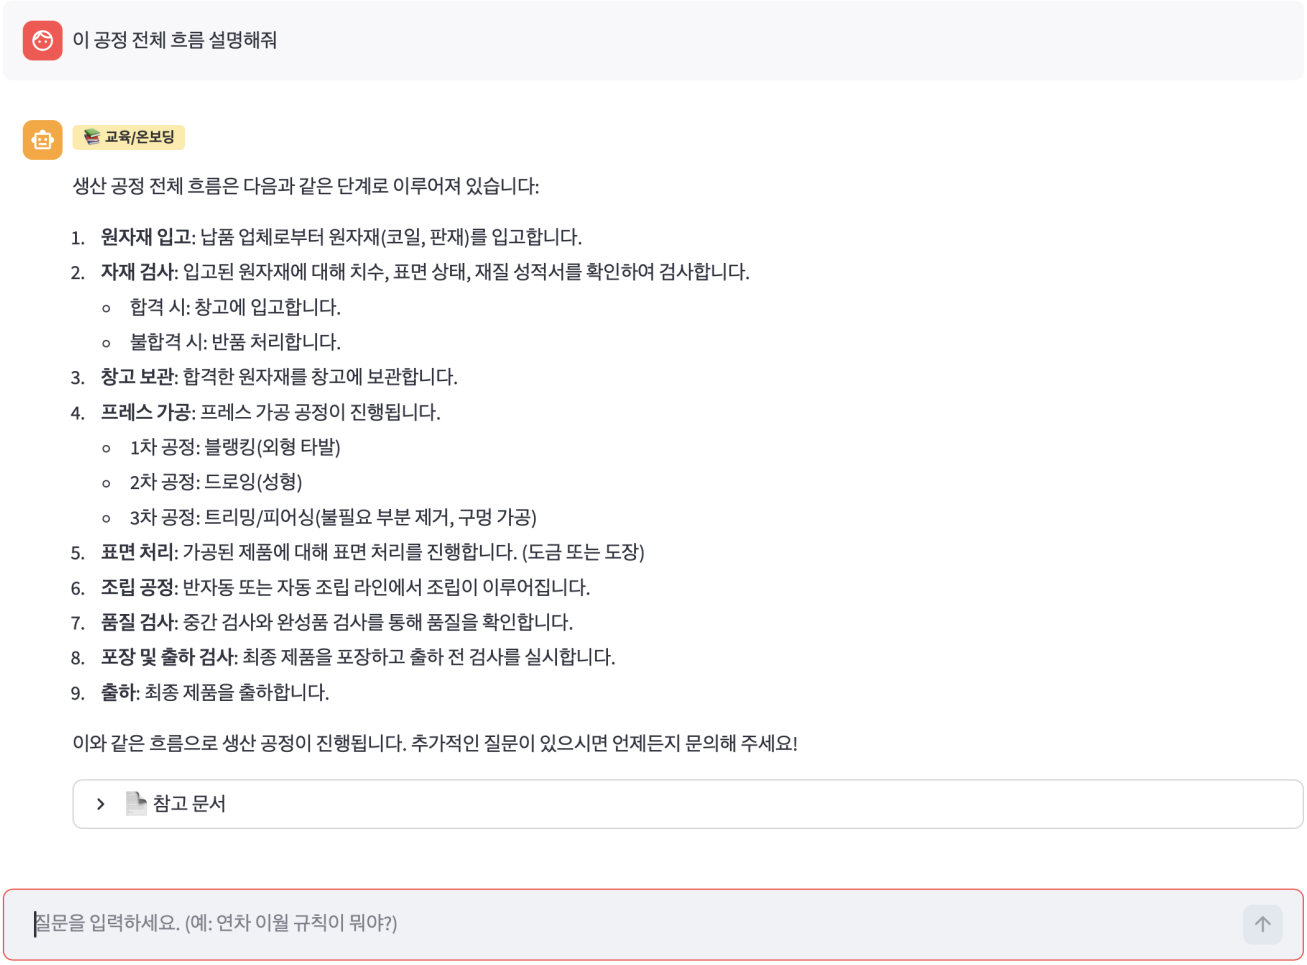

입력: "이 공정 전체 흐름 설명해줘"

- **라우팅 결과**: 교육/온보딩 도메인으로 정확히 분류
- **답변 내용**: 생산 공정 9단계를 순차적으로 설명
  1. 원자재 입고 → 2. 자재 검사 → 3. 창고 보관 → 4. 프레스 가공(블랭킹/드로잉/트리밍) → 5. 표면 처리 → 6. 조립 공정 → 7. 품질 검사 → 8. 포장 및 출하 검사 → 9. 출하

2.6 현장 매뉴얼 도메인 테스트

압력 이상 알람 조치 (`현장매뉴얼_1.png`)

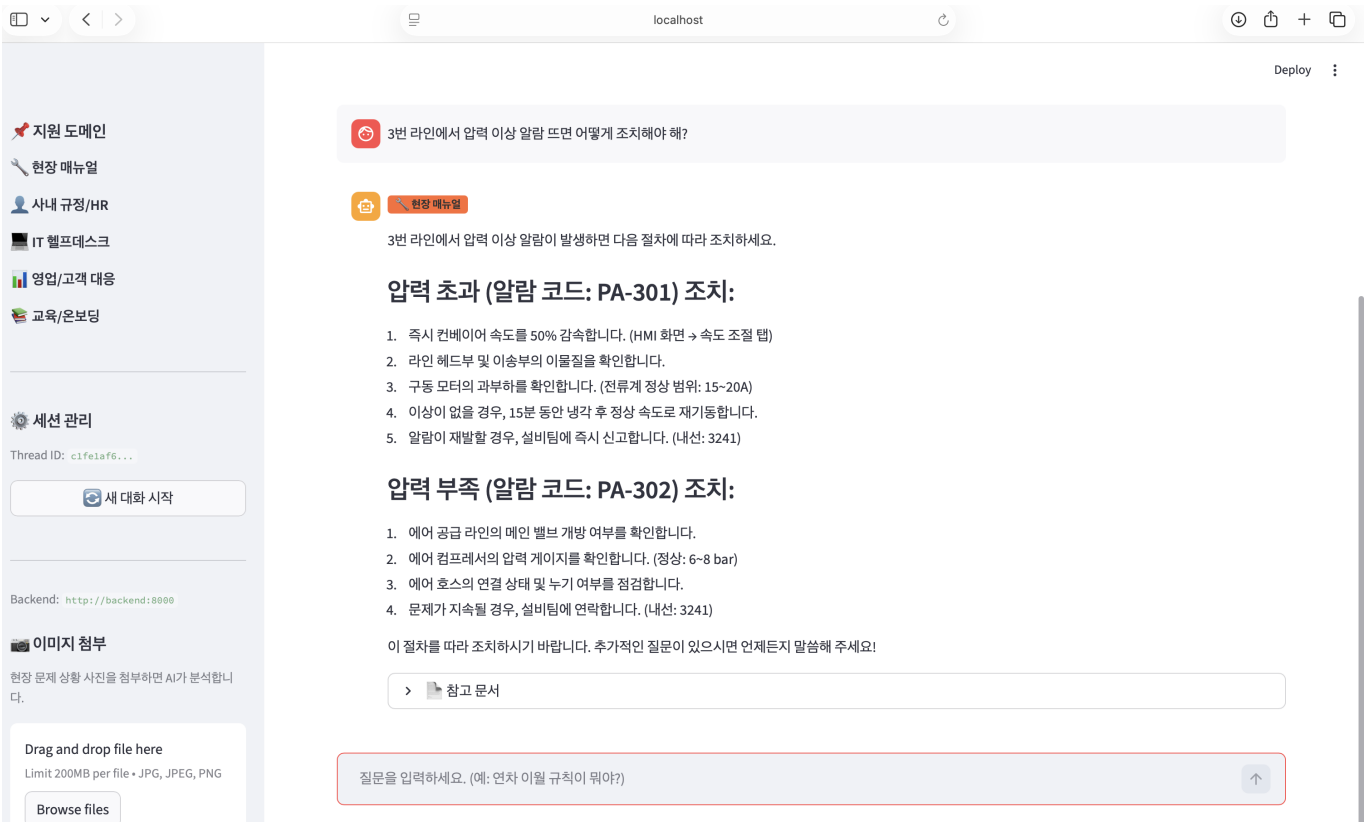

입력: "3번 라인에서 압력 이상 알람 뜨면 어떻게 조치해야 해?"

- **라우팅 결과**: 현장 매뉴얼 도메인으로 정확히 분류
- **답변 내용**: 알람 코드별 조치 절차를 헤더로 구분하여 안내
  - PA-301(압력 초과): 컨베이어 50% 감속 → 이물질 확인 → 모터 과부하 확인(15~20A) → 15분 냉각 후 재기동 → 재발 시 설비팀 신고(내선 3241)
  - PA-302(압력 부족): 메인 밸브 개방 확인 → 에어 컴프레서 압게이지 확인(6~8 bar) → 에어 호스 점검
- **전체 UI 표시**: 좌측 사이드바(도메인 목록, 이미지 첨부)와 우측 채팅 영역이 함께 보이는 전체 레이아웃 캡처

A장비 필터 교체 주기 (현장매뉴얼_2.png)

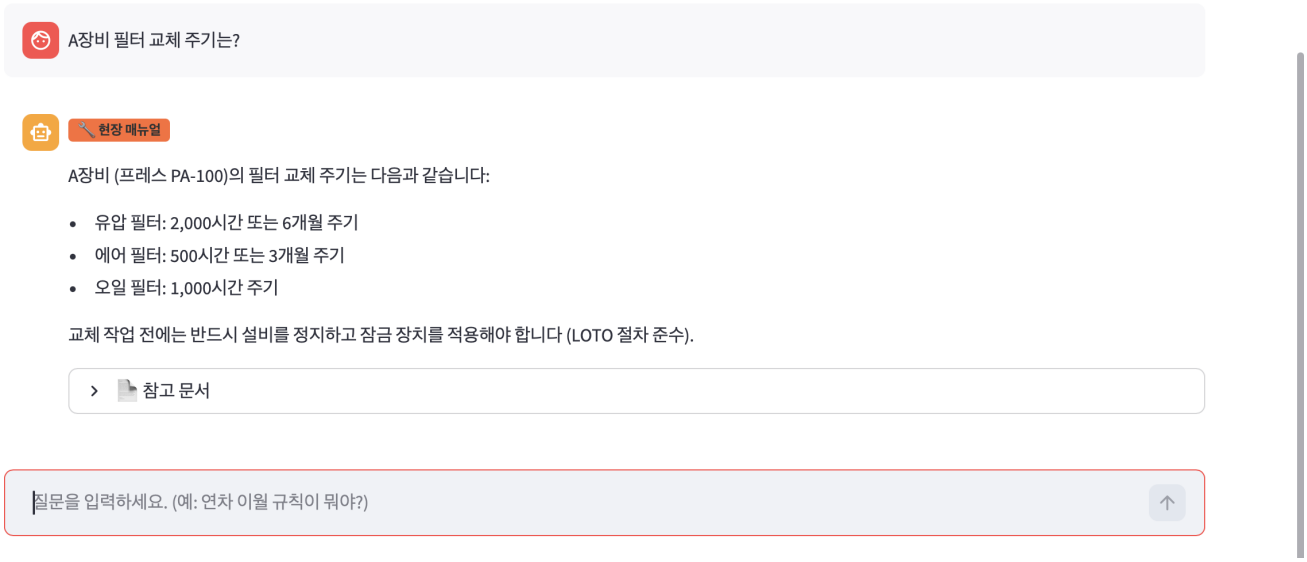

입력: "A장비 필터 교체 주기는?"

- **라우팅 결과**: 현장 매뉴얼 도메인으로 정확히 분류
- **답변 내용**: A장비(프레스 PA-100) 필터 교체 주기를 종류별로 안내
  - 유압 필터: 2,000시간 또는 6개월
  - 에어 필터: 500시간 또는 3개월
  - 오일 필터: 1,000시간
  - 교체 작업 시 LOTO 절차 준수 안전 주의사항 포함

에러 코드 E-204 (현장매뉴얼_3.png)

입력: "에러 코드 E-204 의미가 뭐야?"

- **라우팅 결과**: 현장 매뉴얼 도메인으로 정확히 분류
- **답변 내용**: E-204가 "센서 통신 오류"(센서-PLC 간 통신 문제)임을 설명하고 6단계 조치 절차 안내
  1. 센서 케이블 커넥터 탈거 후 재결합
  2. 케이블 손상/굴곡 확인
  3. PLC 제어판 재부팅(OFF → 10초 대기 → ON)
  4. 재기동 후 5분간 신호 모니터링
  5. 지속 시 유지보수팀 연락(내선 3300)
  6. 센서 교체 필요 시 자재창고(내선 3150) 부품 청구

---

5. 어려웠던 점과 해결 방법

a. 기술적 문제 및 해결 과정

LLM 라우터 신뢰성 문제

- 문제: LLM이 도메인 키 외에 부연 설명이나 잘못된 키워드를 반환하는 경우 발생

- 해결: System Prompt에서 도메인 키 하나만 출력하도록 강력히 제약하고, 유효하지 않은 응답이 오면 한국어 키워드 기반 폴백 함수로 재분류하는 이중 안전장치를 구현했다. 이를 통해 라우팅 정확도 100% 달성

멀티모달 메시지 처리

- 문제: 이미지가 포함된 메시지는 LangChain HumanMessage의 content가 리스트 타입으로 전달되어 기존 문자열 처리 로직이 실패
- 해결: 마지막 사용자 메시지를 역방향으로 탐색하면서 content 타입을 확인하고, 리스트인 경우 `type: "text"` 파트만 추출하는 `_get_last_human_text()` 헬퍼 함수를 별도로 구현

멀티 도메인 벡터 DB 설계

- 문제: 단일 Chroma 컬렉션에 모든 도메인 문서를 넣으면 도메인 간 노이즈 발생, 검색 품질 저하
- 해결: 도메인별로 독립 컬렉션을 구성하고, 라우터가 결정한 도메인의 컬렉션에서만 검색하도록 파이프라인을 설계하여 도메인 간 간섭을 완전히 제거

b. 팀 협업 문제 및 해결 과정

개인 프로젝트로 팀 협업 이슈는 해당 없음

c. 성능 문제 및 해결 과정

- 문제: 요청마다 Chroma 벡터 DB를 새로 로드하면서 첫 응답 이후에도 지연 발생
- 해결: `_retrievers` 딕셔너리를 모듈 레벨에서 유지하여 도메인별 검색기를 최초 1회만 초기화하고 이후 요청에서는 캐시에서 즉시 반환하는 구조로 개선. 응답 지연을 초기화 비용을 첫 요청에만 집중시켜 이후 응답 속도를 대폭 향상

---

6. 회고

a. 배운 기술

- **LangGraph**: StateGraph를 활용한 멀티 노드 AI 파이프라인 설계. TypedDict 기반 상태 관리와 add_messages reducer를 통한 대화 이력 유지 방법을 익혔다.
- **RAG 아키텍처**: 문서 청킹 전략(크기, 오버랩)이 검색 품질에 미치는 영향을 직접 실험하며 최적값을 도출했다.
- **LLM 프롬프트 엔지니어링**: 라우터 LLM이 정확히 도메인 키만 출력하도록 System Prompt를 설계하는 과정에서 제약 조건 명시의 중요성을 체감했다.
- **멀티모달 LLM 연동**: Base64 인코딩을 통한 이미지-텍스트 동시 처리 방식과 LangChain 메시지 타입의 구조를 깊이 이해했다.
- **FastAPI + Streamlit 연동**: REST API 설계와 프론트엔드-백엔드 비동기 통신 구조를 직접 구현했다.
- **Docker Compose 헬스 체크**: 서비스 간 의존성(`depends_on` + `service_healthy`)을 설정하여 안정적인 기동 순서를 보장하는 방법을 배웠다.

b. 개선할 점

- **스트리밍 응답**: 현재는 전체 답변이 완성된 후 한 번에 반환하는 구조로, LLM 스트리밍 API를 활용하면 체감 응답 속도를 크게 향상시킬 수 있다.
- **도메인 라우팅 신뢰도 표시**: 라우터의 분류 확신도(confidence)를 사용자에게 함께 표시하면 잘못된 라우팅 발생 시 사용자가 직접 도메인을 수정할 수 있어 UX가 향상된다.
- **지식 문서 관리 UI**: 현재는 파일 시스템에 직접 .txt 파일을 추가해야 지식 베이스가 갱신된다. 관리자가 웹에서 문서를 업로드·삭제할 수 있는 어드민 UI가 있으면 운영 편의성이 높아진다.

- **평가 파이프라인**: 라우팅 정확도와 답변 품질(관련성, 충실도)을 자동으로 측정하는 RAG 평가 파이프라인(예: RAGAS)을 구축하면 지속적인 품질 관리가 가능하다.

c. 확장 가능성

- **신규 도메인 추가**: `knowledge/` 디렉토리에 새 폴더와 .txt 문서만 추가하면 자동으로 벡터 색인 및 라우팅이 되는 구조로 설계되어 도메인 확장이 용이하다.
- **에이전트 확장**: `tools.py`에 도메인별 RAG 도구가 이미 구현되어 있어 LangGraph 에이전트 아키텍처로의 전환이 용이하다.
- **공정 데이터 연동**: 현재 문서 기반 RAG에 MES·생산 DB 등 실시간 데이터를 추가하면 "이번 주 불량률 원인 분석" 같은 고급 질의도 지원 가능하다.
- **멀티테넌트 지원**: 부서별 독립 지식 베이스와 접근 권한 관리를 추가하면 대규모 기업 환경에 적용 가능하다.
- **보고서 자동 생성**: 축적된 대화 이력과 KPI 문서를 결합하면 관리자용 자동 보고서 생성 기능으로 확장 가능하다.

---

7. 참고 자료

GitHub

https://github.com/kimnamhyeong01/enterprise-llm-rag-chatbot